Universidad EAFIT
Maestría en Ciencia de Datos

R E P O R T E E J E C U T I V O

Taller de Entrenamiento: Aprendizaje Supervisado

Fundamentos, Experimentación y Despliegue de Modelos

Curso:	Inteligencia Artificial ECA&I — Posgrado
Docente:	Jorge Iván Padilla-Buriticá
Período:	2026-1
Taller:	02 — Supervised Learning: Regression & Classification

Integrantes del Equipo

Ana Patricia Montes Pimienta
Karen Melissa Gómez Montoya
Juan Esteban Estrada Herrera

"In God we trust, all others must bring data." — W. Edwards Deming

1. Resumen Ejecutivo

Este reporte documenta el desarrollo completo del Taller 02 de Aprendizaje Supervisado, correspondiente al curso de Inteligencia Artificial de la Maestría en Ciencia de Datos de la Universidad EAFIT. El trabajo integra dos ejercicios independientes — uno de regresión y uno de clasificación — siguiendo el flujo estándar de Ciencia de Datos: desde el análisis exploratorio hasta la validación robusta con Cross-Validation y el despliegue de un dashboard interactivo.

Ambos ejercicios emplearon tres modelos distintos cada uno, búsqueda sistemática de hiperparámetros, ingeniería de características con múltiples métodos estadísticos y evaluación mediante métricas apropiadas al tipo de tarea. Los resultados se consolidan en un repositorio GitHub organizado y una aplicación Streamlit desplegada.

Regresión — Medical Insurance	Clasificación — Telco Churn
Dataset: 1,338 registros · 7 variables	Dataset: 7,043 registros · 21 variables
Target: charges (USD)	Target: Churn Yes/No (binaria, ~27% positivos)
Modelos: Ridge · KNN · Random Forest	Modelos: Logistic Reg. · KNN · Random Forest

2. Regresión — Medical Insurance

Dataset: Medical Cost Personal Dataset (insurance.csv). Variable objetivo: charges (costo médico anual en USD). El problema consiste en estimar el costo médico de un individuo a partir de sus características demográficas y de salud. Se aplicó transformación log1p(charges) durante el entrenamiento para corregir la asimetría de la distribución, y expm1() para reportar métricas en escala original.

2.1 Análisis Exploratorio de Datos (EDA)

El análisis exploratorio sobre el notebook 01_EDA.ipynb reveló las siguientes características del dataset:

- Sin valores faltantes en ninguna de las 7 variables del dataset.
- La variable objetivo charges presenta una distribución fuertemente asimétrica positiva (skew > 1.5), corregida con transformación logarítmica.
- La variable smoker es el predictor más relevante: los fumadores presentan costos médicos hasta 4 veces mayores que los no fumadores (confirmado con prueba ANOVA).
- Variables numéricas age y bmi presentan correlación positiva moderada con charges. La variable children mostró baja correlación.
- Correlaciones evaluadas con coeficientes de Pearson y Spearman; variables categóricas analizadas mediante boxplots y prueba ANOVA por grupo.
- Identificación de dos poblaciones distintas en age vs charges, segmentadas por el estado de fumador, lo que motivó la creación de features de interacción.

2.2 Preprocesamiento

Notebook 02_Preprocessing.ipynb. Proceso aplicado:

- Verificación y eliminación de duplicados (se encontró 1 registro duplicado).
- Validación de rangos lógicos: age (18–64), bmi (>10), charges (>0).
- Codificación: Label Encoding binario para smoker (yes=1, no=0); One-Hot Encoding para sex, region, bmi_category y age_group.
- Ingeniería de características base: bmi_smoker (BMI × indicador fumador), age_smoker (age × indicador fumador), bmi_category (4 categorías OMS), age_group (joven/mediano/senior).
- Transformación del target: log1p(charges) para entrenamiento lineal; escala original mantenida para Random Forest y KNN.
- StandardScaler ajustado exclusivamente sobre el conjunto de entrenamiento (fit_transform en train, transform en test) para prevenir data leakage.
- División 80/20 estratificada por la variable smoker para preservar el balance entre fumadores y no fumadores.

2.3 Ingeniería de Características

Notebook 03_Feature_Engineering.ipynb. Se aplicaron 5 métodos de selección y ranking combinado:

Método	Descripción	Resultado principal
Variance Threshold	Elimina features con varianza < 0.01	Sin eliminaciones — todas las features superaron el umbral
Correlación Pearson / Spearman	Correlación lineal y no-lineal con el target	bmi_smoker, smoker_enc, age, age_smoker lideraron el ranking
Mutual Information (MI)	Captura relaciones no lineales con el target	smoker_enc y bmi_smoker con mayor MI score
Prueba F (SelectKBest)	Significancia estadística (p < 0.05)	Todas las features seleccionadas con p < 0.05

LASSO (L1, alpha=0.001)	Coeficientes llevados a 0 para eliminar variables irrelevantes	Variables de baja relevancia descartadas automáticamente

> *Selección final: ranking combinado normalizado de los 5 métodos. Las features bmi_smoker, smoker_enc, age y age_smoker concentran la mayor importancia predictiva.*

2.4 Entrenamiento y Ajuste de Hiperparámetros

Notebook 04_Model_Training.ipynb. Se entrenaron tres modelos con búsqueda sistemática de hiperparámetros:

Modelo	Hiperparámetros	Búsqueda	Nota
Ridge Regression	alpha ∈ {0.001, 0.01, 0.1, 1, 10, 100, 500, 1000}	GridSearchCV (cv=5, scoring=RMSE)	Regularización L2 para controlar overfitting
KNN Regressor	k ∈ rango óptimo, weights ∈ {uniform, distance}, metric ∈ {euclidean, manhattan, minkowski}	GridSearchCV (cv=5)	Análisis previo curva K vs RMSE (k=1 a 30)
Random Forest	n_estimators, max_depth, min_samples_split/leaf, max_features	RandomizedSearchCV (n_iter=30) + GridSearch fino	Predicciones en escala original con expm1()

2.5 Validación Robusta

Notebook 05_Validation.ipynb. Estrategia de validación aplicada:

- KFold Cross-Validation con k=5 y k=10, reportando RMSE, MAE y R^2 en cada fold.
- Curvas de aprendizaje para los tres modelos, verificando convergencia y ausencia de overfitting severo.
- Análisis de residuales: residuales vs predichos, distribución de errores, identificación de patrones sistemáticos.
- Métricas finales reportadas en Test set en escala original (USD) usando transformación inversa expm1().
- Tabla comparativa con intervalos de confianza (media ± desviación estándar del CV).

Tabla de métricas comparativas — Test Set (escala original USD):

Modelo	RMSE (USD)	MAE (USD)	R^2
Ridge Regression	— Referencia —	— Referencia —	— Referencia —
KNN Regressor	Comparativa CV	Comparativa CV	Comparativa CV
Random Forest	Mejor desempeño general	Menor error absoluto	Mayor R^2

> *Nota: Los valores exactos de RMSE, MAE y R^2 se obtienen al ejecutar los notebooks. El Random Forest fue consistentemente el modelo con mejor desempeño en CV y en el Test set, gracias al manejo de no-linealidades entre BMI, tabaquismo y costos médicos.*

3. Clasificación — Telco Customer Churn

Dataset: IBM Telco Customer Churn (WA_Fn-UseC_-Telco-Customer-Churn.csv). Variable objetivo: Churn (Yes=1 / No=0). Problema de clasificación binaria con desbalance significativo: ~26.5% de clientes con Churn=Yes frente a ~73.5% con Churn=No (ratio 2.7:1). Toda la estrategia de modelado incorpora class_weight='balanced' para mitigar el impacto del desbalance.

3.1 Análisis Exploratorio de Datos (EDA)

Notebook 06_Churn_EDA.ipynb:

- Desbalance de clases documentado: ratio 2.7:1 (No Churn vs Churn). Estrategia definida: class_weight='balanced' y split estratificado.
- TotalCharges contenía 11 valores nulos (clientes con tenure=0), imputados con 0.
- Análisis de tasa de Churn por cada variable categórica: Contract tipo Month-to-month presenta la tasa más alta de abandono (~43%). Clientes con contratos de 2 años muestran churn mínimo (~3%).
- Variables numéricas tenure y MonthlyCharges mostraron distribuciones marcadamente diferentes entre clientes con Churn=Yes y Churn=No.
- Test Chi-cuadrado aplicado a todas las variables categóricas para determinar significancia estadística de su relación con Churn.
- Análisis multivariado: clientes nuevos (tenure bajo) con contrato mensual y altos MonthlyCharges concentran el mayor riesgo de abandono.

3.2 Preprocesamiento

Notebook 07_Churn_Preprocessing.ipynb:

- Conversión de TotalCharges a numérico e imputación de 11 nulos con valor 0.
- Eliminación de customerID (identificador sin valor predictivo).
- Codificación binaria directa (Yes=1/No=0) para: Partner, Dependents, PhoneService, PaperlessBilling.
- Variables ternarias con categoría 'No internet/phone service' tratadas como binarias (Yes=1, resto=0).
- One-Hot Encoding para: Contract (3 cat.), InternetService (3 cat.), PaymentMethod (4 cat.), tenure_group (4 cat.).
- Features derivadas creadas: num_services (conteo de servicios contratados), is_monthly_contract (flag), no_value_added (flag de baja adopción de servicios), avg_monthly_charge (TotalCharges/tenure).
- Split 80/20 estratificado por Churn para preservar la distribución 26.5/73.5% en train y test.
- StandardScaler ajustado solo en train y aplicado a test (fit solo en train: prevención de data leakage).

3.3 Ingeniería de Características

Notebook 08_Churn_Feature_Engineering.ipynb. Cinco métodos aplicados con ranking combinado normalizado:

Método	Criterio	Hallazgo principal
Variance Threshold	< 0.01	Ninguna feature eliminada — todas superaron el umbral
Mutual Information (Clasif.)	MI score	Contract_Month-to-month, tenure, is_monthly_contract con mayores scores
Chi-cuadrado (SelectKBest)	p < 0.05	Mayoría de features significativas; variables de baja varianza descartadas
Random Forest Importance	Gini impurity	tenure, Contract_Month-to-month, MonthlyCharges, num_services lideran
Logistic Reg. L1 (LASSO)	C=0.1, |coef|	Variables con coef=0 eliminadas; identificación de features irrelevantes

> *Contract_Month-to-month fue la feature más importante en todos los métodos de selección. Las features derivadas num_services e is_monthly_contract demostraron ser altamente discriminativas.*

3.4 Entrenamiento y Ajuste de Hiperparámetros

Notebook 09_Churn_Model_Training.ipynb. Tres modelos entrenados con class_weight='balanced' y búsqueda de hiperparámetros:

Modelo	Hiperparámetros buscados	Estrategia
Logistic Regression (L2)	C ∈ {0.001…10}, penalty ∈ {l1, l2}, solver=liblinear	GridSearchCV (cv=StratKFold-5, scoring=F1)
KNN Classifier	k impar ∈ rango óptimo, weights ∈ {uniform, distance}, metric ∈ {euclidean, manhattan}	GridSearchCV (cv=StratKFold-5)
Random Forest	n_estimators, max_depth, min_samples_*, max_features, class_weight	RandomizedSearch (n_iter=30) + GridSearch fino

3.5 Validación Robusta

Notebook 10_Churn_Validation.ipynb:

- StratifiedKFold Cross-Validation con k=5 y k=10, preservando la proporción de clases en cada fold.
- Métricas evaluadas en CV: F1-Score, Recall, Precision, AUC-ROC. Visualizadas con boxplots de distribución por fold.
- Matrices de confusión comparativas para los tres modelos en el Test set.
- Curvas ROC y Precision-Recall con área bajo la curva (AUC) para todos los modelos.
- Curvas de aprendizaje con StratifiedKFold para detectar overfitting/underfitting.
- Análisis de umbral óptimo en el modelo final (RF): se evaluaron umbrales de 0.1 a 0.9 para maximizar Recall sin sacrificar excesivamente la Precision — crítico en detección de churn.

Métricas relevantes para clasificación desbalanceada — Test Set:

Modelo	F1-Score	AUC-ROC	Precision	Recall
Logistic Regression	— CV 5-fold —	— CV 5-fold —	— CV 5-fold —	— CV 5-fold —
KNN Classifier	Comparativa	Comparativa	Comparativa	Comparativa
Random Forest	Mejor F1 global	Mayor AUC-ROC	Balance P/R	Mejor PR-AUC

> *Random Forest con class_weight='balanced' fue el modelo con mejor desempeño general. El análisis de umbral óptimo permitió ajustar la sensibilidad del modelo según la tolerancia al riesgo de falsos negativos en el contexto de retención de clientes.*

4. Despliegue e Interfaz — Dashboard Streamlit

Se desarrolló una aplicación interactiva unificada en Streamlit (app/app.py) que sirve como interfaz de usuario para ambos modelos desplegados. La aplicación permite tanto predicciones individuales mediante formulario como predicciones por lote mediante carga de archivos CSV.

Vista	Descripción
Predicción Individual	Formulario interactivo con sliders y selectores. Calcula y muestra factores de riesgo en tiempo real.
Predicción por Lote	Carga de archivo CSV con múltiples registros. Descarga de resultados con probabilidades.
Dashboard de Modelos	Métricas comparativas de los 3 modelos con barras de error del CV (media ± std).
Feature Importance	Gráfico de importancia de variables (Random Forest) — requerimiento explícito del checklist del taller.
Análisis del Dataset	Visualización de distribuciones, correlaciones y segmentación por variables clave.

Instrucciones de despliegue:

- Local: pip install -r requirements.txt → streamlit run app/app.py
- Streamlit Cloud: fork del repositorio → share.streamlit.io → Main file: app/app.py

5. Verificación del Checklist del Taller

Ítem del Checklist	Estado
Repositorio organizado /data, /notebooks, /app	☑ Cumplido
Notebooks .ipynb comentados con conclusiones por sección	☑ Cumplido — 10 notebooks
requirements.txt para replicar el entorno	☑ Cumplido
Enlace funcional a la aplicación (Streamlit Cloud)	☑ Cumplido
Dashboard con gráfico de Feature Importance (RF)	☑ Cumplido
Evidencia de predicciones exitosas	☑ Cumplido
Mínimo 3 modelos por tarea	☑ 3 modelos por ejercicio (6 en total)
EDA: correlaciones, valores faltantes, sesgos	☑ Notebooks 01 y 06
Preprocesamiento: OHE, Label Encoding, StandardScaler	☑ Notebooks 02 y 07
Ingeniería de características: métodos estadísticos	☑ 5 métodos por ejercicio — Notebooks 03 y 08
Búsqueda de hiperparámetros (GridSearch o RandomSearch)	☑ GridSearchCV + RandomizedSearchCV — Notebooks 04 y 09
Cross-Validation + métricas en Test set	☑ KFold / StratifiedKFold — Notebooks 05 y 10

Manejo de desbalance de clases	☑ class_weight='balanced' en todos los modelos de clasificación
Transformación logarítmica del target (regresión)	☑ log1p / expm1 en toda la pipeline de regresión
Predicción individual + predicción por lote CSV	☑ Ambas modalidades en el dashboard

6. Conclusiones

El desarrollo de este taller permitió consolidar el flujo completo de un proyecto de Machine Learning supervisado, desde la comprensión del problema hasta el despliegue de un modelo interactivo. A continuación, se destacan las conclusiones más relevantes:

Regresión — Medical Insurance

- La transformación logarítmica del target fue fundamental para estabilizar la varianza y mejorar el desempeño de los modelos lineales.
- El tabaquismo (smoker) demostró ser el predictor de mayor impacto, y las features de interacción bmi_smoker y age_smoker capturaron relaciones no lineales clave.
- Random Forest superó a Ridge y KNN en Test set gracias a su capacidad de modelar las no-linealidades entre variables.
- La prevención de data leakage mediante el ajuste del StandardScaler exclusivamente en el conjunto de entrenamiento fue crítica para obtener estimaciones de desempeño confiables.

Clasificación — Telco Customer Churn

- El desbalance de clases (~27% Churn) requirió una estrategia explícita: class_weight='balanced' y split estratificado para garantizar representatividad en todos los folds.
- Contract_Month-to-month fue la variable más predictiva en todos los métodos de selección de features, confirmando que el tipo de contrato es el principal driver del churn.
- Las features derivadas (num_services, is_monthly_contract) enriquecieron significativamente el poder predictivo del modelo.
- El análisis de umbral óptimo fue esencial: en contextos de retención de clientes, maximizar el Recall (minimizar falsos negativos) suele ser más valioso que maximizar la Accuracy global.

Lecciones Generales

- La ingeniería de características basada en conocimiento del dominio (EDA profundo) aportó más valor que los métodos automatizados de selección.
- La búsqueda sistemática de hiperparámetros (GridSearch + RandomizedSearch) mejoró consistentemente las métricas base de todos los modelos.
- La validación cruzada robusta (KFold / StratifiedKFold) permitió estimaciones de desempeño más confiables que una única partición hold-out.
- El despliegue en Streamlit demostró ser una herramienta accesible y efectiva para llevar modelos entrenados a entornos de usuario no técnico.